

UrbanIQ

Inteligência Analítica, Estatística e Tomada de Decisão

A cidade Alfa investiu em sensores inteligentes.

Este relatório responde se esse investimento chega até o cidadão.



MAPA INICIAL DA MISSÃO

Item	Definição
Desafio escolhido	10 — Centro de Operações Urbanas (COU)
Nome do grupo	DataGuy
Integrante	Thiago Fiel de Oliveira — RM 570088 — Turma 1TSCO
Base de dados	cidade_alfa_ocorrencias_urbanas.xlsx — 10.180 registros × 29 colunas
Código-fonte	DataGuy_PBL_Fase_5.ipynb — 140 células, Partes 0 a 3

1 O problema a ser resolvido

A cidade Alfa unificou suas fontes de dados em um Centro de Operações Urbanas: sensores IoT, câmeras de alta definição, aplicativo, portal web e telefone 156 alimentam a mesma central. O investimento em detecção automática foi alto, e a pergunta da gestão pública é direta — esse dinheiro virou serviço melhor para quem mora na cidade?

Hipótese de trabalho: para uma ocorrência sair do mundo real e virar serviço prestado, ela percorre quatro elos. A cadeia é tão forte quanto o elo mais fraco, então cada elo foi testado separadamente, com uma técnica estatística adequada à sua natureza.

2 A cadeia de valor do COU

Elo	Pergunta	Técnica aplicada
1 • Detecção	O sensor vê o problema antes do cidadão?	Teste t de Welch, d de Cohen
2 • Despacho	A central aciona a equipe por prioridade?	Correlação de Pearson e Spearman, qui-quadrado, V de Cramér
3 • Execução	A equipe resolve igual em toda a cidade?	ANOVA, Kruskal-Wallis
4 • Percepção	O cidadão percebe a diferença?	Correlação, regressão linear

3 Entregáveis desta fase

Relatório (este PDF)

Mapa da missão e as evidências dos três desafios, com as imagens geradas na execução e as considerações de cada etapa.

Código-fonte único

DataGuy_PBL_Fase_5.ipynb reúne a massa de dados, a limpeza, a análise estatística e o código do painel em Streamlit.

1º DESAFIO — PREPARAÇÃO E QUALIDADE DOS DADOS

1 A massa de dados e o que foi plantado nela


A base foi construída pelo grupo com semente aleatória fixa em **570088** (o RM), o que a torna reproduzível: gerar de novo produz exatamente os mesmos registros. Quatro padrões fortes foram embutidos de propósito, para que os testes tivessem o que detectar, e três relações ficaram deliberadamente fracas — inclusive a hipótese central da gestão, que **não se confirma**. Uma análise honesta precisa poder refutar uma hipótese.

```
bairro nulo ..... 120      dt_encerramento < dt_abertura ..... 25
satisfacao = 9 (fora da escala) ..... 40      dt_abertura no futuro ..... 20
satisfacao nula por falha de envio ..... 60      fonte_dado sem padronizacao ..... 300
tempo_resposta negativo ..... 30      custo_operacional absurdo ..... 3
score_prioridade = 999 ..... 50      linhas duplicadas ..... 180
```

Defeitos plantados de propósito na geração — matéria-prima do 1º desafio

2 Diagnóstico e tratamento

Nove tipos de inconsistência foram diagnosticados e tratados. Duas decisões orientaram a limpeza: **nulo legítimo foi separado de nulo defeituoso** — ocorrências em aberto não têm data de encerramento por definição, e são justamente as mais relevantes para um Centro de Operações — e **a limpeza atuou na célula, não na linha**, preservando informação válida que uma exclusão apressada teria descartado.




Outliers de custo operacional identificados por boxplot antes do tratamento

Indicador	Base bruta	Base tratada
Total de registros	10.180	9.980
Registros duplicados	180	0
Rótulos distintos de fonte_dado	10	5
Scores fora da faixa 0-100	50	0
Bairros nulos	122	0 ("Não Informado")

A perda de linhas ficou em **1,96%** — baixa justamente porque a maior parte dos problemas foi corrigida no nível da célula. A base tratada foi exportada como `cidade_alfa_ocorrencias_ajustado.xlsx`, insumo da Parte 2 e do painel.


2º DESAFIO — ANÁLISE ESTATÍSTICA (ELOS 1 E 2)

1 Amostragem e Teorema Central do Limite



Distribuição das médias amostrais convergindo para a normal — base da inferência aplicada adiante


2 Elo 1 — Detecção: o sensor cumpre o que promete



Tempo de resposta por natureza da fonte — teste t de Welch com p praticamente zero

A detecção automática chega ao local em aproximadamente **metade do tempo** do canal humano. O teste t de Welch confirma a diferença com p praticamente zero, e o d de Cohen indica **tamanho de efeito grande**. O elo 1 funciona.


3 Elo 2 — Despacho: onde a cadeia quebra



Score de prioridade × tempo até o acionamento — a fila ignora a prioridade calculada


2º DESAFIO — ANÁLISE ESTATÍSTICA (ELOS 3 E 4)

4 Elo 3 — Execução: funciona, mas de forma desigual



A ANOVA e o Kruskal-Wallis convergem: as regiões **diferem de forma estatisticamente significativa**, com p praticamente zero. A amplitude entre a melhor e a pior região é grande demais para ser variação operacional. Duas pessoas com o mesmo problema recebem serviços de qualidade diferente conforme onde moram.

5 Elo 4 — Percepção: o cidadão pune a promessa quebrada



Entre todas as variáveis testadas, a que mais se correlaciona com a satisfação não é o tempo absoluto de atendimento, e sim a **razao_sla** — a razão entre o tempo gasto e o prazo prometido. Resolver em 60 h com prazo de 72 satisfaz mais que resolver em 8 h com prazo de 6.

6 Armadilhas estatísticas identificadas e descartadas

Falácia ecológica

A correlação entre custo e satisfação muda de sinal quando se agrega por bairro. A conclusão foi tirada no nível individual.

Correlação tautológica

Variáveis derivadas umas das outras correlacionam por construção, não por relação real. Foram excluídas da leitura.


2º DESAFIO — LIMITES, DERIVADAS E INTEGRAIS

O material da fase pede a aplicação de cálculo à análise. Aqui ele não é decorativo: cada operação responde a uma pergunta de operação do Centro.

7 Derivada — a demanda está acelerando?




8 Integral — o passivo urbano acumulado




9 Limite — contratar mais equipes ainda compensa?

3º DESAFIO — VISUALIZAÇÃO DE DADOS

O diagnóstico virou um **painel interativo em Streamlit** (`app_urbanIQ.py`), com filtros por região, categoria e canal, uma aba por elo da cadeia e uma aba de recomendações. O painel atende aos três níveis da gestão: operacional (mapa e tempos por etapa), tático (os elos com seus indicadores) e estratégico (KPIs de topo e recomendações).



Painel · Elo 1 — tempo de resposta por canal de origem



Painel · Elo 2 — a reta praticamente horizontal mostra que a fila ignora a prioridade


RECOMENDAÇÕES PARA A GESTÃO PÚBLICA

Cada recomendação nasce de um resultado estatístico deste relatório. Nenhuma é opinião: todas trazem a evidência que as sustenta.

#	Recomendação	Evidência
1	Ordenar a fila de despacho pelo score de prioridade. Hoje a central atende por ordem de chegada — o motor de priorização é calculado e ignorado. É mudança de software, não de orçamento.	Elo 2 · correlação não significativa
2	Medir o SLA a partir da detecção, não do registro. O sensor entrega quase metade do tempo de resposta, e isso não aparece no indicador.	Elo 2 · V de Cramér ≈ 0
3	Realocar equipes para as regiões com pior desempenho. A diferença entre a melhor e a pior região é estrutural, não ruído.	Elo 3 · ANOVA com $p \approx 0$
4	Renegociar os prazos prometidos por categoria. O cidadão reage mais à promessa quebrada do que à demora em si.	Elo 4 · razão do SLA supera o tempo absoluto
5	Dimensionar a operação para a demanda real. A taxa de chegada supera a capacidade instalada e o backlog cresce continuamente.	Cálculo · limite e derivada da espera

A recomendação 1 é a de maior retorno sobre esforço: não pede verba, não pede pessoal e não pede obra. Pede que um número **que já é calculado** passe a ser usado na ordenação da fila.

CONCLUSÃO



Síntese — o diagnóstico dos quatro elos da cadeia de valor do COU

A cidade Alfa investiu em sensores inteligentes, e esse investimento **chega até o elo 2, e para ali**. O sensor cumpre o que promete, mas o ganho é devolvido por completo no despacho, porque a central atende por ordem de chegada. Adiante, a execução funciona de forma territorialmente desigual, e o cidadão percebe — e pune mais a promessa quebrada do que a demora em si.

O resultado mais valioso não é nenhum dos gráficos: é ter encontrado **onde** a cadeia quebra. Uma cidade que sabe qual é o seu elo fraco pode consertá-lo. Uma que não sabe compra mais sensores.

CADERNO DE EVIDÊNCIAS DA EXECUÇÃO

Esta última parte do relatório existe para um único fim: **comprovar que o notebook foi executado de ponta a ponta**. Cada imagem a seguir é a captura direta da saída de uma célula de `DataGuy_PBL_Fase_5.ipynb`, na ordem em que aparece no arquivo.

Cada célula que gera evidência imprime a própria identidade no topo da saída, no formato `CAPTURA nn`. O contador entre colchetes do Colab muda a cada reexecução e por isso não serve como referência estável — a numeração impressa, sim. É ela que amarra cada imagem deste caderno à célula que a produziu.

Capturas	Etapa do notebook	Desafio
01 a 09	Carga, diagnóstico de qualidade e relatório da limpeza	1º — Preparação e qualidade
10 a 13	Estatística descritiva, amostragem e intervalo de confiança	2º — Análise estatística
14 a 22	Os quatro elos: teste t, correlação, qui-quadrado, ANOVA e regressão	2º — Análise estatística
23 a 27	Derivada, integral, limite e armadilhas estatísticas	2º — Análise estatística
30 a 33	Síntese do diagnóstico e prévias do painel em Streamlit	3º — Visualização

As capturas **31 a 33** foram geradas na execução em máquina limpa, com o notebook sozinho numa pasta vazia: ele instalou as bibliotecas que faltavam, reconstruiu a massa de dados a partir do gerador embutido na Parte 0 e rodou as 140 células sem nenhum erro.

CAPTURA 01 | Dicionário de dados da base — descrição das 29 colunas

1.2 Carga do arquivo Excel

Arquivos

salidas_fase5

sample_data

cidade_alfa_ocorrencias_ajustad...

cidade_alfa_ocorrencias_urbana...

marcar(1, "Dicionário de dados da base")

dicionario

CAPTURA 01 | Dicionário de dados da base

Coluna	Descrição
0 id_ocorrendia	Identificador unico da ocorrencia registrada n...
1 id_ponto_monitorado	Ponto fixo de monitoramento (apenas fontes aut...
2 fonte_dado	Canal de origem: APP_MOBILE, PORTAL_WEB, TELEF...
3 tipo_fonte	CIDADAO (registro humano) ou AUTOMATICA (senso...
4 dt_abertura	Data e hora do registro da ocorrencia
5 dt_despacho	Data e hora do acionamento da equipe responsavel
6 dt_chegada_equipe	Data e hora da chegada da equipe ao local
7 dt_encerramento	Data e hora do encerramento (nulo se ainda em ...
8 regiao	Regiao da cidade Alfa: Centro, Norte, Sul, Les...
9 bairro	Bairro da ocorrencia
10 densidade_hab_km2	Densidade populacional do bairro em habitantes...
11 latitude	Latitude do ponto da ocorrencia
12 longitude	Longitude do ponto da ocorrencia
13 categoria	Categoria do problema urbano
14 subcategoria	Detalhamento do problema dentro da categoria
15 criticidade_sensor	Criticidade avaliada na deteccao, escala de 1 a 5
16 score_prioridade	Score de priorizacao do UrbanIQ, de 0 a 100 (R...
17 sla_horas_previsao	Prazo de atendimento acordado para a categoria...
18 tempo_resposta_min	Minutos entre a abertura e a chegada da equipe...
19 tempo_resolucao_horas	Horas entre a abertura e o encerramento da oco...
20 sla_cumprido	SIM, NAO ou EM ABERTO, conforme o prazo previsto
21 status_ocorrencia	ABERTO, EM_ANALISE, EM_ATENDIMENTO, RESOLVIDO ...
22 equipe_acionada	Equipe operacional responsavel pelo atendimento
23 qtd_pessoas_afetadas	Estimativa de pessoas impactadas pela ocorrencia

CAPTURA 02 | Estrutura, tipos e preenchimento por coluna (df.info)

1.3 Conhecendo a base

Arquivos

salidas_fase5

sample_data

cidade_alfa_ocorrencias_ajustad...

cidade_alfa_ocorrencias_urbana...

Tipos de dados e quantidade de valores preenchidos por coluna

marcar(2, "Estrutura da base: tipos e preenchimento")

df.info()

CAPTURA 02 | Estrutura da base: tipos e preenchimento

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 10180 entries, 0 to 10179

Data columns (total 29 columns):

Column Non-Null Count Dtype

0 id_ocorrendia 10180 non-null int64

1 id_ponto_monitorado 10180 non-null object

2 fonte_dado 10180 non-null object

3 tipo_fonte 10180 non-null object

4 dt_abertura 10180 non-null datetime64[ns]

5 dt_despacho 10180 non-null datetime64[ns]

6 dt_chegada_equipe 10180 non-null datetime64[ns]

7 dt_encerramento 8029 non-null datetime64[ns]

8 regiao 10180 non-null object

9 bairro 10065 non-null object

10 densidade_hab_km2 10180 non-null int64

11 latitude 10180 non-null float64

12 longitude 10180 non-null float64

13 categoria 10180 non-null object

14 subcategoria 10180 non-null object

15 criticidade_sensor 10180 non-null int64

16 score_prioridade 10180 non-null int64

17 sla_horas_previsao 10180 non-null int64

18 tempo_resposta_min 10180 non-null int64

19 tempo_resolucao_horas 8029 non-null float64

20 sla_cumprido 10180 non-null object

21 status_ocorrencia 10180 non-null object

22 equipe_acionada 10180 non-null object

23 qtd_pessoas_afetadas 10180 non-null int64

24 custo_operacional_reais 10180 non-null float64

25 satisfacao_cidadao 5627 non-null float64

26 reincidencia_30d 10180 non-null object

27 temperatura_c 10180 non-null float64


28 chuva_mm 10180 non-null float64

dtypes: datetime64[ns](4), float64(7), int64(7), object(11)

memory usage: 2.3+ MB

CAPTURA 03 Valores nulos por coluna — primeiro diagnóstico de qualidade

1.4 Diagnóstico · problema 1



```
# Quantidade e percentual de valores nulos por coluna
marcar(3, "Valores nulos por coluna")

nulos = pd.DataFrame({
    "qtd_nulos": df.isnull().sum(),
    "pct_nulos": (df.isnull().sum() / len(df)) * 100, round(2)
})
nulos[nulos["qtd_nulos"] > 0].sort_values("qtd_nulos", ascending=False)
```

CAPTURA 03 | Valores nulos por coluna

	qtd_nulos	pct_nulos
satisfacao_cidadao	4553	44.72
dt_encerramento	2151	21.13
tempo_resolucao_horas	2151	21.13
bairro	122	1.20


Reflexão de negócio. Nem todo nulo é um defeito, e essa distinção é o ponto mais importante desta etapa.

Coluna	Nulo significa	É defeito?
dt_encerramento	A ocorrência ainda está em aberto	Não. É informação legítima
tempo_resolucao_horas	Consequência do item acima	Não
satisfacao_cidadao	Ocorrência não finalizada ou cidadão não respondeu	Parcial
bairro	O endereço não foi confirmado no atendimento	Sim

Tratar todo nulo da mesma forma, apagando linhas, destruiria justamente as ocorrências em aberto, que são as mais urgentes para um Centro de Operações. Vamos confirmar essa hipótese cruzando os nulos com o status.

CAPTURA 04 Nulos cruzados com o status — separando nulo legítimo de nulo defeituoso

1.4 Diagnóstico · problema 1



```
# Os nulos de dt_encerramento correspondem mesmo às ocorrências não finalizadas?
marcar(4, "Nulo legítimo x nulo defeituoso: status x dt_encerramento")

pd.crosstab(
    df["status_ocorrencia"],
    df["dt_encerramento"].isnull(),
    colnames=["dt_encerramento é nulo"]
)
```

CAPTURA 04 | Nulo legítimo x nulo defeituoso: status x dt_encerramento


dt_encerramento é nulo	False	True
status_ocorrencia		
ABERTO	0	515
EM_ANALISE	0	666
EM_ATENDIMENTO	0	970
ENCERRADO	6406	0
RESOLVIDO	1623	0

Confirmado: os nulos de dt_encerramento aparecem somente nos status ABERTO, EM_ANALISE e EM_ATENDIMENTO. Não é sujeira, é o ciclo de vida da ocorrência.

CAPTURA 06

Falta de padronização em fonte_dado — 10 rótulos para 5 canais reais

1.4 Diagnóstico · problema 5



```
# Todos os valores distintos encontrados na coluna fonte_dado
marcar(6, "Padronização: 10 rótulos distintos para 5 fontes reais")

print("Valores distintos em fonte_dado: {}".format(df['fonte_dado'].unique()))
print()
for valor in sorted(df['fonte_dado'].unique()):
    print(f" {valor} -> {(df['fonte_dado'] == valor).sum()} registros")

CAPTURA 06 | Padronização: 10 rótulos distintos para 5 fontes reais
Valores distintos em fonte_dado: 10


[ app_mobile ] -> 88 registros
[ camera_hd ] -> 36 registros
[ APP_MOBILE ] -> 2787 registros
[ CAMERA_HD ] -> 1165 registros
[ PORTAL_WEB ] -> 1713 registros
[ Portal Web ] -> 55 registros
[ SENSOR_IOT ] -> 1953 registros
[ Sensor_IOT ] -> 59 registros
[ TELEFONE_156 ] -> 2299 registros
[ telefone 156 ] -> 65 registros
```

São 10 rótulos para apenas 5 fontes reais. Os colchetes no print revelam os espaços em branco no início e no fim, que passariam despercebidos numa leitura comum.

CAPTURA 07

Outliers extremos de custo operacional

1.4 Diagnóstico · problema 6



CAPTURA 08 Relatório das 9 etapas de limpeza aplicadas

1.7 Relatório da limpeza

Arquivos

saídas_fase5

07-heatmap-custo.png

sample_data

cidade_alpha_ocorrencias_ajustad...

cidade_alpha_ocorrencias_urbana...

1.7 Relatório da limpeza

O que mudou entre a base bruta e a base tratada.

```
marcar(8, "Relatório das 9 etapas de limpeza")
relatorio = pd.DataFrame(registro_limpeza)
relatorio
```

CAPTURA 08 | Relatório das 9 etapas de limpeza

	etapa	registros_afetados	linhas_antes	linhas_depois
0	1. Duplicatas removidas	180	10180	10000
1	2. fonte_dado padronizada	5	10000	10000
2	3. bairro nulo preenchido	120	10000	10000
3	4. score_prioridade = 999 anulado	50	10000	10000
4	5. satisfacao fora da escala anulada	40	10000	10000
5	6. tempo_resposta negativo anulado	30	10000	10000
6	7. dados invertidos anulados	38	10000	10000
7	8. registros com data futura removidos	20	10000	9980
8	9. custo absurdo anulado	3	9980	9980

Próximas etapas: [Gerar código com relatorio](#) [New interactive sheet](#)

CAPTURA 09 Base bruta x base tratada — o efeito medido da limpeza

1.7 Relatório da limpeza

Arquivos

saídas_fase5

07-heatmap-custo.png

sample_data

cidade_alpha_ocorrencias_ajustad...

cidade_alpha_ocorrencias_urbana...

4 comparação direta entre antes e depois

marcar(9, "Base bruta x base tratada")

```
comparacao = pd.DataFrame([
    "base bruta": [
        len(df_original),
        df_original.duplicated().sum(),
        df_original["fonte_dado"].nunique(),
        (df_original["score_prioridade"] > 100).sum(),
        (df_original["tempo_resposta_min"] < 0).sum(),
        df_original["bairro"].isnull().sum(),
        f"R$ {df_original['custo_operacional_realis'].max():.4f}",
    ],
    "base tratada": [
        len(df_c),
        df_c.duplicated().sum(),
        df_c["fonte_dado"].nunique(),
        (df_c["score_prioridade"] > 100).sum(),
        (df_c["tempo_resposta_min"] < 0).sum(),
        df_c["bairro"].isnull().sum(),
        f"R$ {df_c['custo_operacional_realis'].max():.4f}",
    ],
], index=[
    "Total de registros",
    "Registros duplicados",
    "Núcleos distintos de fonte",
    "Scores fora da faixa 0-100",
    "Tempos de resposta negativos",
    "Bairros nulos",
    "Custo máximo",
])
```

CAPTURA 09 | Base bruta x base tratada

	base bruta	base tratada
Total de registros	10180	9980
Registros duplicados	180	0
Núcleos distintos de fonte	19	5
Scores fora da faixa 0-100	50	0
Tempos de resposta negativos	30	0
Bairros nulos	122	0
Custo máximo	R\$ 10,000,000	R\$ 9.871

Próximas etapas: [Gerar código com comparacao](#) [New interactive sheet](#)

CAPTURA 10 Estatística descritiva da base tratada

2.1 Estatística descritiva

Arquivos

salidas_fase5

sample_data

cidade_alpha_ocorrencias_ajustad...

cidade_alpha_ocorrencias_urbana...

Comandos

Código

Texto

Executar tudo

Antes de testar qualquer hipótese é preciso conhecer o comportamento das variáveis. A descritiva responde três perguntas: qual é o valor típico, quanta variação existe em torno dele, e a distribuição é simétrica ou puxada para um lado.

Essa última pergunta é a mais importante e a mais ignorada. Ela decide se a média é uma medida honesta ou enganosa.

marcar(10, "Estatística descritiva das variáveis da cadeia")

variaveis = ["tempo_resposta_min", "lag_despacho_min", "tempo_resolucao_horas", "razao_sla", "score_prioridade", "satisfacao_cidadao",]

descriptiva = df[variaveis].describe().T

descriptiva["assimetria"] = df[variaveis].skew()

descriptiva["cv_%"] = (descriptiva["std"] / descriptiva["mean"] * 100).round(1)

descriptiva.round(2)

CAPTURA 10 | Estatística descritiva das variáveis da cadeia

	count	mean	std	min	25%	50%	75%	max	assimetria	cv_%
tempo_resposta_min	9.950.000	84.750	54.660	9.000	47.000	71.000	106.000	679.000	2.080	64.500
lag_despacho_min	9.980.000	31.430	27.900	2.000	14.000	23.000	40.000	424.000	3.250	88.800
tempo_resolucao_horas	7.857.000	33.340	34.920	0.630	10.710	22.330	43.870	461.810	3.020	104.700
razao_sla	7.857.000	0.970	0.670	0.080	0.530	0.800	1.230	8.800	2.230	68.500
score_prioridade	9.930.000	63.300	21.560	1.000	47.000	64.000	80.000	100.000	-0.130	34.100
satisfacao_cidadao	5.485.000	3.220	0.860	1.000	3.000	3.000	4.000	5.000	-0.140	26.600

Como ler esta tabela.

O coeficiente de variação (cv_%) é o desvio padrão em proporção da média. Acima de 50% indica um processo instável: o tempo de atendimento não é confiável, varia demais de um caso para outro. Para uma central de operações, isso é um problema por si só, independente da média estar boa.

A assimetria positiva revela que a média está sendo puxada por uma cauda de casos extremos. Quando ela aparece, a mediana descreve melhor o caso típico do que a média. É por isso que vamos reportar as duas.

CAPTURA 11 Distribuição do tempo de resolução — média, mediana e assimetria

2.1 Estatística descritiva

Tempo de resolução: assimetria à direita

ocorrências

horas até o encerramento

Média: 33.3 h

Mediana: 22.3 h

Tempo de resolução por região

Centro

Sul

Oeste

Norte


Leste

horas

Thiago Fiel de Oliveira | RM 570088 | Grupo DataGuy | FIAP 2026

CAPTURA 13 Amostragem e Teorema Central do Limite

2.2 Amostragem e intervalo de confiança



CAPTURA 14 Elo 1 — teste t de Welch, resultado do scipy e do pingouin

2.3 ELO 1 — Detecção

```
marcar[14, "ELO 1 - Teste t: fonte automática x canal humano"]

automatica = dfc.loc[dfc.tipo_fonte == "AUTOMATICA", "tempo_resposta_min"].dropna()
cidadao = dfc.loc[dfc.tipo_fonte == "CIDADAO", "tempo_resposta_min"].dropna()

# Método 1: scipy.stats
t_stat, p_valor = st.ttest_ind(automatica, cidadao, equal_var=False, alternative="two-sided")

print(f"Fonte AUTOMATICA n={len(automatica):>5} média={automatica.mean():>6.1f} min mediana={automatica.median():>6.1f} min")
print(f"Fonte CIDADAO n={len(cidadao):>5} média={cidadao.mean():>6.1f} min mediana={cidadao.median():>6.1f} min")
print()
print(f"Diferença absoluta ..... {cidadao.mean() - automatica.mean():.1f} min")
print(f"Ganho relativo ..... {(1 - automatica.mean() / cidadao.mean()) * 100:.1f}%")
print()
print("---- scipy.stats.ttest_ind ----")
print(f"Estadística t ..... {t_stat:.2f}")
print(f"Valor-p ..... {p_valor:.3e}")
print()
print(f"DECISÃO: ('rejeitamos H0' if p_valor < 0.05 else 'não rejeitamos H0') (α = 0.05)")
print(f"O ELO 1 FUNCIONA." if p_valor < 0.05 and automatica.mean() < cidadao.mean() else "O ELO 1 NÃO se confirma.")
```

CAPTURA 14 | ELO 1 - Teste t: fonte automática x canal humano

Fonte	n	média	min	mediana
AUTOMATICA	3149	54.5	47.0	47.0
CIDADAO	6881	98.8	85.0	85.0

Diferença absoluta 44.3 min
Ganho relativo 44.8%

--- scipy.stats.ttest_ind ---
Estadística t -49.59
Valor-p 0.000e+00

DECISÃO: rejeitamos H0 (α = 0.05)
O ELO 1 FUNCIONA.

O `scipy.stats` entrega a estatística t e o valor-p. O `pingouin` entrega o mesmo teste com informações que a decisão de gestão precisa: o tamanho do efeito (cohen-d), o intervalo de confiança da diferença e o poder do teste.

Poder próximo de 1 significa risco baixo de Erro Tipo II, ou seja, de deixar de detectar uma diferença que existe de verdade.

CAPTURA 14 Elo 1 — tamanho de efeito (d de Cohen) e poder estatístico

2.3 ELO 1 — Detecção

```
Arquivos
  -
  - saídas_fase5
  - sample_data
  - cidade_alpha_ocorrencias_ajustad...
  - cidade_alpha_ocorrencias_urbana...

# Método 2: pinguin, com tamanho de efeito e poder
resultado_pg = pg.ttest(x=automatica, y=cidadao, alternative="two-sided",
                        confidence=0.95, correction=True)


d_cohen = col_pg(resultado_pg, "cohen-d", "cohen_d").iloc[0]
poder = resultado_pg["power"].iloc[0]

print("--- pinguin.ttest ---")
print(resultado_pg.round(4).to_string())
print()
print(f"D de Cohen ... (d_cohen:3f) "
      f"('grande' if abs(d_cohen) >= 0.8 else 'médio' if abs(d_cohen) >= 0.5 else 'pequeno')")
print(f"Poder ..... (poder:3f) "
      f"('risco baixo' if poder > 0.8 else 'atenção') de Erro Tipo II)")

--- pinguin.ttest ---
      t      dof alternative p_val      CI95 cohen_d power BF10
T_test -49.595 9,690.997 two-sided 0.000 [-46.03, -42.53] 0.875 1.000 inf
d de Cohen ... 0.874 (grande)
Poder ..... 1.000 (risco baixo de Erro Tipo II)
```

CAPTURA 15 Elo 1 — tempo de resposta por natureza da fonte


2.3 ELO 1 — Detecção



CAPTURA 16

Elo 2 — correlação entre score de prioridade e tempo de despacho

2.4 ELO 2 — Despacho



The screenshot shows a Jupyter Notebook titled 'DataGuy_PBL_Fase_5.ipynb'. The code in the cell performs the following steps:

- Imports necessary libraries: `marcar`, `dfc`, `st` (statsmodels), `pd` (pandas).
- Filters data for 'Elo 2a' based on priority score and dispatch time.
- Calculates Pearson and Spearman correlation coefficients between priority score and dispatch time.
- Prints the results of the correlation analysis.
- Performs a hypothesis test to determine if the correlation is statistically significant.
- Calculates the median dispatch time for different priority score ranges.

The output of the code is as follows:

```
CAPTURA 16 | ELO 2a - O score de prioridade influencia o tempo até o despacho?
n = 9,930 ocorrências

Pearson (relação linear)    r = -0.0097    p = 0.3344
Spearman (relação monótona) r = -0.0127    p = 0.2040

Variação explicada (r²) ... 0.01%


DECISÃO: não rejeitamos H0. NÃO há relação detectável.
O score é calculado, mas NÃO é usado na fila de despacho.

Tempo mediano até o despacho por faixa de prioridade:
n      mediana_min  mediana_max
0-25 baixa      409      22.000      31.300
26-50 média    2513      24.000      32.100
51-75 alta     3074      23.000      31.100
76-100 crítica 3134      23.000      31.300
```

CAPTURA 17

Elo 2 — qui-quadrado e V de Cramér entre fonte e cumprimento de SLA

2.4 ELO 2 — Despacho



The screenshot shows a Jupyter Notebook titled 'DataGuy_PBL_Fase_5.ipynb'. The code in the cell performs the following steps:

- Imports necessary libraries: `marcar`, `dfc`, `st` (statsmodels), `pd` (pandas).
- Filters data for 'Elo 2b' based on SLA fulfillment.
- Creates a contingency table for source and SLA fulfillment.
- Calculates the chi-square statistic and Cramér's V coefficient.
- Prints the results of the chi-square and Cramér's V analysis.
- Performs a hypothesis test to determine if there is a significant association between source and SLA fulfillment.

The output of the code is as follows:

```
CAPTURA 17 | ELO 2b - A fonte do dado influencia o cumprimento do SLA?

Tabela de contingência:
sla_cumprido  NAO  SIM
tipo_fonte
AUTOMATICA      900  1579
CIDADAO        1957  3421


% dentro do prazo:
AUTOMATICA      63.7%
CIDADAO         63.6%

Qui-quadrado ..... 0.00    gl = 1
Valor-p ..... 0.9627
V de Cramér ..... 0.0000 (0 = nenhuma associação, 1 = total)

DECISÃO: não rejeitamos H0. NÃO há associação.
O ganho de 45 minutos na detecção NÃO se converte em prazo cumprido.
```


CAPTURA 18 Elo 2 — a fila ignora a prioridade calculada

2.4 ELO 2 — Despacho




CAPTURA 19 Elo 3 — ANOVA e Kruskal-Wallis entre as regiões

2.5 ELO 3 — Execução




CAPTURA 20 Elo 3 — desigualdade territorial no cumprimento do prazo

2.5 ELO 3 — Execução



CAPTURA 21 Elo 4 — matriz de correlação das variáveis da cadeia

2.6 ELO 4 — Percepção



CAPTURA 22 Elo 4 — regressão linear da satisfação do cidadão

2.6 ELO 4 — Percepção


A satisfação cai conforme o prazo prometido é estourado




CAPTURA 23 Derivada simbólica calculada com SymPy

2.7.1 Derivada

Função ajustada ao volume mensal




Derivada: simbólica x numérica




CAPTURA 23 Derivada — taxa de variação da demanda ao longo do tempo

2.7.1 Derivada




CAPTURA 24 Integral — comparação dos três métodos de integração

2.7.2 Integral




CAPTURA 24 Integral — passivo urbano acumulado (área sob a curva)

2.7.2 Integral




CAPTURA 25 Limite — ponto de saturação do ganho por equipe adicional

2.7.3 Limite




CAPTURA 27 Armadilha — falácia ecológica demonstrada com os próprios dados

2.8 Armadilhas estatísticas



CAPTURA 30 Síntese — o diagnóstico dos quatro elos da cadeia

2.9 Síntese do diagnóstico




CAPTURA 31

Painel · Elo 1 — tempo de resposta por canal de origem

3.3 Prévia dos painéis

Elo 1 — o sensor detecta em metade do tempo do canal humano



CAPTURA 32

Painel · Elo 2 — a reta horizontal que revela o elo quebrado

3.3 Prévia dos painéis

Elo 2 — prioridade alta não é despachada antes

